Отчёт по Практике 7: Рекомендательные системы на основе веб-данных

1. Постановка задачи и выбор датасетов

Целью работы является построение и сравнение трёх подходов к рекомендациям (контентного, коллаборативного на явных данных и коллаборативного на неявных данных) с обязательным сравнением с бейзлайном «популярное». Выбор датасета определяет постановку задачи, поэтому были взяты два датасета с разными типами обратной связи:

1. MovieLens (ml-latest-small) — явные оценки (от 0,5 до 5). Позволяет проверить алгоритм SVD (библиотека surprise).
2. Last.fm HetRec 2011 — неявная обратная связь (факты прослушивания). Позволяет проверить алгоритм ALS (библиотека implicit), которому не нужны явные рейтинги.

2. Разведочный анализ данных (EDA)

После фильтрации получены следующие характеристики:

- MovieLens: 610 пользователей, 3650 фильмов, 90 274 взаимодействия, разреженность матрицы 95,9%.
- Last.fm: 1859 пользователей, 2823 исполнителя, 71 355 прослушиваний, разреженность матрицы 98,6%.

Распределение оценок в MovieLens смещено в сторону высоких (чаще всего ставят 3, 4 и 5), что типично для кино (рис. 1). Популярность объектов имеет «длинный хвост»: небольшое количество фильмов имеет сотни оценок (максимум порядка 300), а многие объекты имеют мало оценок (после k-core фильтра — не меньше 5). Высокая разреженность (98,6% в Last.fm) означает, что у пользователей мало пересечений в истории, что затрудняет поиск похожих пользователей в коллаборативной фильтрации.

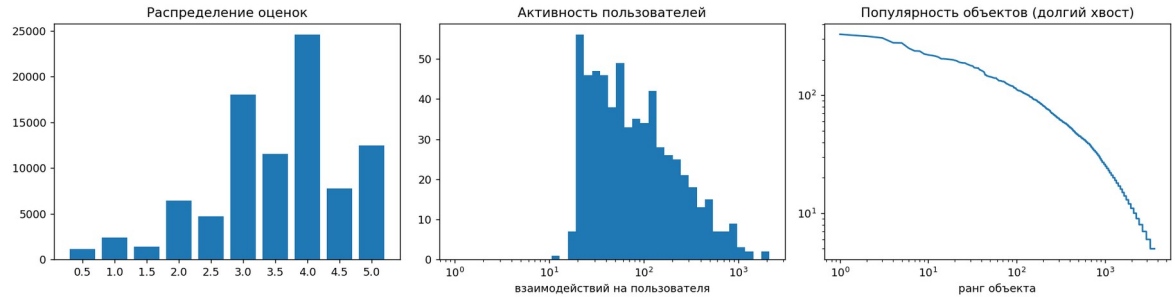


Рис. 1 — EDA для MovieLens: распределение оценок, активность пользователей, популярность объектов (длинный хвост)

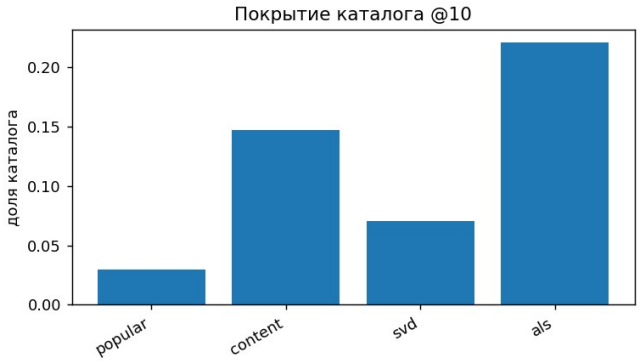


Рис. 2 — Покрытие каталога моделями на MovieLens (K = 10)

3. Методы и протокол оценки

Для корректного эксперимента реализован следующий протокол.

- **Сплит.** Поюзерный. MovieLens — хронологический (последние 5 взаимодействий пользователя в тест), так как есть временные метки. Last.fm — случайный leave-N-out (5 взаимодействий, seed = 42), так как времени прослушиваний в данных нет. Пользователи с историей менее 10 взаимодействий целиком остаются в train, а пользователи без релевантных объектов в тесте исключаются из оценки. В итоге оценивались 545 пользователей MovieLens (из 610) и 1833 пользователя Last.fm (из 1859).
- **Бейзлайн.** Модель popular рекомендует каждому пользователю самые популярные из ещё не виденных им объектов. Без неё оценка остальных моделей была бы невозможна.
- **Модели.** popular (бейзлайн); content (TF-IDF по жанрам, названиям и тегам, профиль пользователя — среднее векторов понравившегося, косинусное сходство); svd (матричное разложение на явных оценках, surprise); als (Alternating Least Squares на неявных данных, implicit). На MovieLens ALS обучался на бинаризованных данных: положительными считались оценки ≥ 4, поэтому он и SVD решают формально разные задачи.
- **Метрики.** Precision@K, Recall@K, MAP@K, NDCG@K (K = 10), а также покрытие каталога, разнообразие выдачи (intra-list diversity в пространстве TF-IDF), новизна и число жанров в списке. Ранжирование выполняется по всему каталогу за вычетом объектов из train.
- **Релевантность.** MovieLens: положительное взаимодействие — рейтинг ≥ 4. Last.fm: релевантно любое прослушивание.
- **Фильтрация.** Из обоих датасетов удалены пользователи и объекты с менее чем 5 взаимодействиями (k-core); дубликаты пар «пользователь–объект» схлопнуты.
- **Сегментация.** Метрики считались в целом и отдельно для «лёгких» и «тяжёлых» пользователей. Граница — медиана числа train-взаимодействий среди оцениваемых пользователей: 60 для MovieLens и 36 для Last.fm.
- **Значимость.** К метрикам приведены 95% доверительные интервалы по пользователям. Различие считается значимым, если интервалы не пересекаются (консервативный критерий).
- **Воспроизводимость.** Все запуски выполнены с seed = 42. Версии: scikit-surprise 1.1.5, implicit 0.7.3, numpy 2.2.6.
- **Лицензии.** MovieLens предоставлен GroupLens Research для некоммерческих исследований; Last.fm HetRec 2011 доступен для академических целей.

4. Результаты эксперимента

4.1. MovieLens (явные данные)

Модель	P@10	R@10	MAP@10 (± ci95)	NDCG@10 (± ci95)	Покры-тие	Разно-образие	Новизна	Жанров в списке
popular	0,0187	0,0531	0,0234 (± 0,0064)	0,0425 (± 0,0099)	2,9%	0,948	1,48	10,7
content	0,0020	0,0064	0,0015 (± 0,0011)	0,0038 (± 0,0023)	14,6%	0,288	5,45	6,85
svd	0,0084	0,0221	0,0080 (± 0,0033)	0,0170 (± 0,0056)	7,0%	0,966	3,25	11,0
als	0,0277	0,0868	0,0288 (± 0,0073)	0,0563 (± 0,0108)	22,0%	0,955	2,64	11,42

Таб. 1 — Результаты на MovieLens (K = 10, 95% доверительные интервалы)

1. SVD значимо хуже бейзлайна. MAP@10 у SVD 0,0080 ± 0,0033 против 0,0234 ± 0,0064 у popular; интервалы не пересекаются. SVD минимизирует RMSE, то есть ошибку предсказания самой оценки, и не оптимизирует ранжирование. Новизна SVD выше, чем у бейзлайна (3,25 против 1,48): он рекомендует более редкие фильмы. Это согласуется с предположением, что редким фильмам с малым числом высоких оценок он завышает предсказание, но напрямую это не проверялось — для проверки нужно сопоставить предсказанные и фактические оценки. Бейзлайн же рекомендует проверенные временем хиты.

2. ALS не отличим от бейзлайна. MAP@10 у ALS 0,0288 ± 0,0073, у popular 0,0234 ± 0,0064; интервалы пересекаются, на 545 оцениваемых пользователях нельзя утверждать, что ALS точнее. Зато покрытие каталога у ALS на порядок выше (22,0% против 2,9%). При этом ALS значимо лучше SVD (нижняя граница 0,0215 против верхней 0,0113), но это сравнение не вполне симметрично из-за разной постановки (бинаризованные данные у ALS).

3. Контентная модель значимо хуже бейзлайна (MAP@10 0,0015 ± 0,0011). Вероятная причина — слишком грубые признаки (жанры, названия, теги), по которым профиль пользователя плохо отличает фильмы; кроме того, модель не учитывает популярность. Выдача при этом самая однородная: разнообразие 0,288 и всего 6,85 жанра в списке против 11,42 у ALS.

Влияние объёма истории. Преимущество ALS над бейзлайном сосредоточено среди лёгких пользователей и почти исчезает среди тяжёлых (табл. 2); на Last.fm картина та же (табл. 4).

Модель	MAP@10, лёгкие (≤ 60)	MAP@10, тяжёлые (> 60)	Отношение лёгкие / тяжёлые
popular	0,0270	0,0196	1,38
als	0,0366	0,0209	1,75
als / popular	1,36	1,07	—

Таб. 2 — MAP@10 по сегментам пользователей (MovieLens)

У обеих моделей метрика выше на лёгких пользователях, но ALS выигрывает у popular в 1,36 раза на лёгких и всего в 1,07 раза на тяжёлых (NDCG@10 у ALS: 0,0703 и 0,0418). Возможное объяснение — у тяжёлых пользователей более разнообразные вкусы, которые модель с фиксированными гиперпараметрами предсказывает хуже, — это гипотеза, не проверенная экспериментом. Доверительные интервалы для сегментов не приведены; в сегментах 276 и 269 пользователей, поэтому различия между сегментами следует считать ориентировочными.

4.2. Last.fm (неявные данные)

Модель	P@10	R@10	MAP@10 (± ci95)	NDCG@10 (± ci95)	Покрытие	Разнообразие	Новизна
popular	0,0428	0,0855	0,0390 (± 0,0040)	0,0772 (± 0,0065)	0,9%	0,684	2,29
content	0,0725	0,1450	0,0631 (± 0,0048)	0,1256 (± 0,0075)	52,4%	0,502	6,06
als	**0,0899**	**0,1797**	**0,0733 (± 0,0050)**	**0,1482 (± 0,0076)**	**54,2%**	**0,787**	**4,60**

Таб. 3 — Результаты на Last.fm (K = 10, 95% доверительные интервалы)

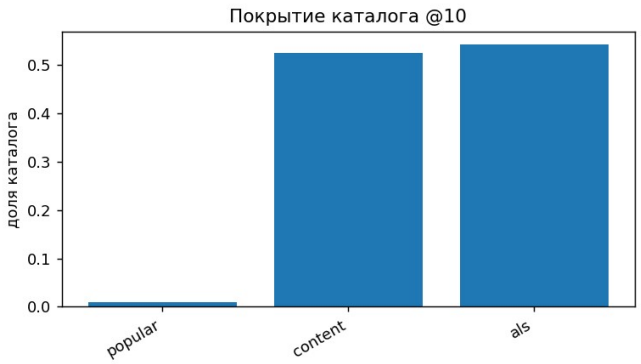


Рис. 3 — Покрытие каталога моделями на Last.fm (K = 10)

1. ALS лидирует. Интервалы MAP@10 у ALS (0,0733 ± 0,0050) и у content (0,0631 ± 0,0049) не пересекаются, поэтому ALS значимо точнее контентной модели; обе модели значимо точнее бейзлайна (0,0390 ± 0,0040). Зазор при этом небольшой: нижняя граница ALS (0,0683) лишь на 0,0004 выше верхней границы content (0,0680), то есть различие лежит на границе принятого критерия.

2. Бейзлайн даёт очень низкое покрытие, но не нулевую точность. Покрытие popular — 0,9%: в выдачах всех пользователей вместе встречается около 28 разных исполнителей (0,99% от 2823), среди

них самые популярные (Lady Gaga, Britney Spears). По точности popular хуже ALS, но заметно лучше нуля (MAP@10 0,0390), то есть как бейзлайн он сильный. Для музыкального сервиса такая выдача была бы неприемлемо однообразной.

3. Контентная модель показала самую высокую новизну (6,06) и покрытие 52,4%, но точность ниже, чем у ALS. Возможная причина — шумность пользовательских тегов, на которых строятся признаки исполнителей.

Влияние объёма истории. На Last.fm граница сегментов — 36 взаимодействий (937 лёгких и 896 тяжёлых пользователей).

Модель	MAP@10, лёгкие (≤ 36)	MAP@10, тяжёлые (> 36)	Отношение лёгкие / тяжёлые
popular	0,0214	0,0574	0,37
content	0,0651	0,0610	1,07
als	0,0706	0,0761	0,93
als / popular	3,30	1,33	—

Таб. 4 — MAP@10 по сегментам пользователей (Last.fm)

Бейзлайн сильно зависит от объёма истории: у лёгких пользователей его MAP@10 (0,0214) почти втрое ниже, чем у тяжёлых (0,0574), тогда как ALS и content почти не меняются. Поэтому преимущество персонализированных моделей над popular сосредоточено среди пользователей с короткой историей (ALS лучше бейзлайна в 3,3 раза на лёгких и в 1,33 раза на тяжёлых), как и на MovieLens. Интервалы для сегментов не рассчитывались, поэтому различия ориентировочные.

4.3. Влияние MMR на разнообразие (MovieLens, контентная модель)

Для смягчения «пузыря фильтров» алгоритм MMR (Maximal Marginal Relevance) был применён к контентной модели, где проблема проявляется сильнее всего.

Модель	MAP@10	NDCG@10	Разнообразие (ILD)	Жанров в списке
Content (без MMR)	0,0015	0,0038	0,2880	6,85
Content + MMR (λ = 0,9)	0,0018	0,0041	0,2929	6,92
Content + MMR (λ = 0,7)	0,0019	0,0041	0,3203	7,27
Content + MMR (λ = 0,5)	0,0018	0,0045	0,3727	7,82

Таб. 5 — Влияние параметра λ в MMR (MovieLens, content, K = 10)

При λ = 0,5 разнообразие выдачи растёт (ILD с 0,288 до 0,373, число жанров с 6,85 до 7,82). Рост ILD отчасти предсказуем: он измеряется в том же TF-IDF-пространстве, по которому MMR штрафует схожесть, поэтому надёжнее ориентироваться на число жанров, где эффект скромнее (+14%). Точность практически не меняется: прирост MAP@10 с 0,0015 до 0,0018 лежит внутри интервала ± 0,0011 и не является значимым. Таким образом, на контентной модели MMR повышает разнообразие без видимой потери точности, но базовая точность этой модели настолько низка, что вывод о цене диверсификации сделать нельзя.

5. Ручной разбор рекомендаций

Для разбора выбраны по два пользователя на датасет (файлы cases.md). В скрытом тесте у каждого по пять релевантных объектов; сводка попаданий в top-10 приведена в таблице 6.

Пользователь (попаданий из 5)	popular	content	svd	als
MovieLens, № 53	0	0	0	0
MovieLens, № 55	0	0	0	1
Last.fm, № 168	0	0	—	0
Last.fm, № 174	0	2	—	0

Таб. 6 — Число попаданий в скрытый тест в top-10 (ручной разбор)

MovieLens, пользователь 53 (15 взаимодействий в train, все оценены на 5). История разнородна: комедии (Airheads, Return of the Pink Panther, Duck Soup), sci-fi и триллеры (The Arrival, Island of Dr. Moreau), романтика и драмы (Sunset Blvd., Days of Thunder, Benny & Joon), хоррор (Halloween). Скрытый тест — романтика, драма, триллер (Roman Holiday, Immortal Beloved, When a Man Loves a Woman, Kalifornia, The Ghost and the Darkness). Ни одна модель не попала ни в один из пяти фильмов.

- **ALS:** «Kingpin» и «Clerks» продолжают комедийную линию истории — согласна. Но остальная выдача (Citizen Kane, The Sting, The Thin Red Line, American History X) — признанная классика без явной связи с историей пользователя; ближе всего к тесту «Jerry Maguire» (романтика).
- **Content:** первые шесть рекомендаций — драмы и романтические драмы («The Descendants», «The Cooler», «The Artist», «The Majestic»), затем четыре комедии. По жанровым меткам это ближе всего к скрытому тесту (Roman Holiday — Drama и Romance), хотя попаданий нет. Выдача однородна: современные комедийные и романтические драмы.
- **SVD:** «Godfather», «Shawshank Redemption», «Fight Club», «Pulp Fiction» — три из десяти рекомендаций совпадают с бейзлайном popular. Это согласуется с метриками: SVD рекомендует признанные хиты и слабо персонализирован. «Dr. Strangelove» в MovieLens помечен жанром War.
- **Popular:** список один и тот же для всех пользователей (у пользователя 55 он идентичен): «Shawshank Redemption», «Forrest Gump», «Pulp Fiction»… Не согласна как с персональной рекомендацией.

MovieLens, пользователь 55 (20 взаимодействий, оценки от 0,5 до 4,5). В истории преобладают криминальные триллеры и драмы (Lucky Number Slevin, Crash, Bourne Ultimatum, Ronin, Payback); скрытый тест — криминальные триллеры (Lock, Stock and Two Smoking Barrels, Snatch, Layer Cake, The Departed, The Boondock Saints).

- **ALS:** единственная модель с попаданием — «The Departed» (6-е место). Рядом «Bourne Supremacy», «Italian Job», «Enemy of the State», «Batman Begins» — тот же криминально-триллерный кластер; согласна с выдачей.
- **Content:** жанр угадан (Crime/Thriller: «Fracture», «Swordfish», «Smokin’ Aces»), но попаданий нет: по жанровым меткам нельзя отличить нужные фильмы от десятков других криминальных. Часть выдачи («Elektra», «Spectre», «Highlander: Endgame») — боевики, а не детективные триллеры.
- **SVD:** общие хиты («American History X», «Shawshank», «Forrest Gump»), без попаданий; «Trainspotting» (Crime и Drama) ближе к вкусу пользователя.

Last.fm, пользователь 168 (33 взаимодействия). История — инди и электроника (Animal Collective, Why?, Flying Lotus, of Montreal, Deerhunter, Boards of Canada, Burial). Скрытый тест: Gorillaz, Los Campesinos!, Daedelus, Fever Ray, Foals.

- **ALS:** инди-часть профиля отражена хорошо (Beirut, Neutral Milk Hotel, Yeasayer, Bon Iver, Sigur Rós, The Flaming Lips) — согласна, исполнители близки по духу. Однако попаданий нет, и почти не отражена электронная ветвь истории (Flying Lotus, Burial, Boards of Canada, Bonobo), к которой относятся Daedelus и Fever Ray из теста.
- **Content:** смешанная выдача (Thom Yorke, M83, Beach House, The Postal Service, Moby), включает и электронику, но тоже без попаданий.
- **Popular:** Lady Gaga, Britney Spears, Rihanna — не согласна, это не связано с нишевыми вкусами пользователя.

Last.fm, пользователь 174 (40 взаимодействий). В истории поп-рок и singer-songwriter 1990–2000-х (John Mayer, Hanson, Coldplay, Death Cab for Cutie, Dave Matthews Band, Snow Patrol). Скрытый тест: James Blunt, The Doors, Foo Fighters, Goo Goo Dolls, Third Eye Blind.

- **Content:** два попадания из пяти («Goo Goo Dolls» на первом месте, «James Blunt» на шестом); выдача (Jason Mraz, Jack Johnson, Jeff Buckley, Alanis Morissette) точно отражает вкус — согласна.

- **ALS:** ноль попаданий. Выдача (Maroon 5, Weezer, Led Zeppelin, Oasis, Pearl Jam, The Beatles, Elvis Presley) в целом подходит под «рок», но тяготеет к самым известным исполнителям и менее специфична, чем у контентной модели.

Выводы разбора. (1) Попаданий в тест мало: во всех 14 парах «модель — пользователь» вместе набралось только 3 попадания (при 5 скрытых объектах на пользователя), поэтому отсутствие попадания нельзя считать ошибкой модели — выдача может быть разумной, а тест слишком мал. (2) Рейтинг моделей зависит от пользователя: на агрегированных метриках ALS лидирует на Last.fm, а у пользователя 174 контентная модель попала дважды, а ALS — ни разу. (3) Контентная модель на Last.fm по метрикам намного сильнее, чем на MovieLens; вероятная причина — более информативные теги исполнителей по сравнению с жанрами фильмов (гипотеза). Разбор основан на четырёх пользователях и носит иллюстративный характер.

6. Обсуждение: проблема «пузыря фильтров»

Бейзлайн popular создаёт «глобальный пузырь»: всем показывают почти одно и то же (покрытие 0,9% на Last.fm и 2,9% на MovieLens). Контентная модель создаёт «персональный пузырь»: на MovieLens её выдача самая однородная (разнообразие 0,288, 6,85 жанра в списке против 11,42 у ALS), то есть пользователя замыкает в узком круге жанров. ALS даёт наибольшее покрытие (22,0% на MovieLens, 54,2% на Last.fm) и разнообразие на уровне бейзлайна, однако на MovieLens по точности значимо не превосходит popular, поэтому говорить о «лучшем балансе» можно только на Last.fm, где ALS значимо точнее и бейзлайна, и контентной модели.

MMR на контентной модели повышает разнообразие (число жанров с 6,85 до 7,82) при неизменной в пределах погрешности точности. Это относительно дешёвый приём, не требующий переобучения, но его эффект на метриках ILD частично объясняется самим способом измерения. Выбор λ — компромисс, зависящий от продукта, универсального значения нет.

7. Ограничения

3. Гиперпараметры (50 факторов, число итераций) взяты из стартовых рекомендаций лекции; подбор на валидационной выборке не проводился.
4. Last.fm: временных меток нет, использован случайный leave-N-out. Это может завышать метрики, так как модель видит прослушивания, которые по времени могли быть после тестовых.
5. Холодный старт не тестировался: в датасетах после k-core фильтра нет новых пользователей и объектов, а в MovieLens (ml-latest-small) его почти нет и по природе данных. Результаты SVD и ALS могут быть оптимистичнее, чем в реальной среде.
6. Пользователи с историей менее 10 взаимодействий в оценку не вошли, как и пользователи без релевантных объектов в тесте.
7. Значимость проверялась по пересечению доверительных интервалов (консервативно), без парного теста или bootstrap. Для сегментов интервалы не рассчитывались.
8. Разнообразие считается в том же TF-IDF-пространстве, в котором работают контентная модель и MMR, поэтому оно смещено в их пользу.
9. ALS на MovieLens обучался на бинаризованных оценках, SVD — на исходных, поэтому их сравнение не полностью симметрично.
10. Ручной разбор выполнен для четырёх пользователей (по два на датасет) и не репрезентативен.

Заключение

Обучены и сравнены четыре модели на двух датасетах. На явных данных (MovieLens) SVD значимо уступил бейзлайну, а контентная модель — тем более; ALS по точности не отличим от бейзлайна, но даёт на порядок большее покрытие и значимо лучше SVD. Преимущество ALS сосредоточено у пользователей с короткой историей. На неявных данных (Last.fm) ALS значимо точнее и контентной модели, и бейзлайна, и обеспечивает покрытие 54,2% против 0,9%. Простейший бейзлайн оказался

сильным соперником, что подтверждает необходимость сравнения с ним. MMR повышает разнообразие контентной выдачи без значимой потери точности. Пайплайн воспроизводим (CLI, seed = 42). Основные ограничения: не проведён подбор гиперпараметров, не тестировался холодный старт, значимость оценена консервативным методом.