Отчет по Практике 7: Рекомендательные системы на основе веб-данных

1. Постановка задачи и выбор датасетов

Целью работы является построение и сравнение трех подходов к рекомендациям (контентного, коллаборативного на явных данных и коллаборативного на неявных данных) с обязательным сравнением с бейзлайном "популярное". Выбор датасета определяет постановку задачи, поэтому были взяты два датасета с разными типами обратной связи:

1. MovieLens (ml-latest-small) - явные оценки (от 0,5 до 5). Позволяет проверить алгоритм SVD (библиотека surprise).
2. Last.fm HetRec 2011 - неявная обратная связь (факты прослушивания). Позволяет проверить алгоритм ALS (библиотека implicit), которому не нужны явные рейтинги.

2. Разведочный анализ данных (EDA)

После фильтрации получены следующие характеристики:

- MovieLens: 610 пользователей, 3650 фильмов, 90 274 взаимодействия, разреженность матрицы 95,9%.
- Last.fm: 1859 пользователей, 2823 исполнителя, 71 355 прослушиваний, разреженность матрицы 98,6%.

Распределение оценок в MovieLens смещено в сторону высоких (чаще всего ставят 3, 4 и 5), что типично для кино (рис. 1). Популярность объектов имеет "длинный хвост": небольшое количество фильмов имеет сотни оценок (максимум порядка 300), а многие объекты имеют мало оценок (после k-core фильтра - не меньше 5). Высокая разреженность (98,6% в Last.fm) означает, что у пользователей мало пересечений в истории, что затрудняет поиск похожих пользователей в коллаборативной фильтрации.

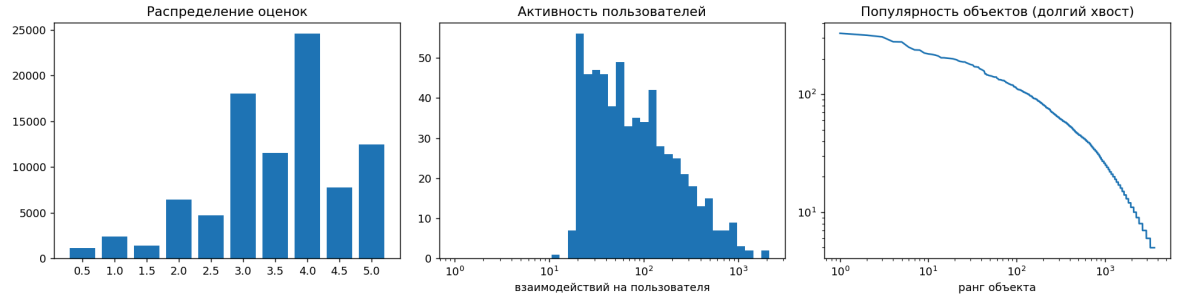


Рис. 1 - EDA для MovieLens: распределение оценок, активность пользователей, популярность объектов (длинный хвост)

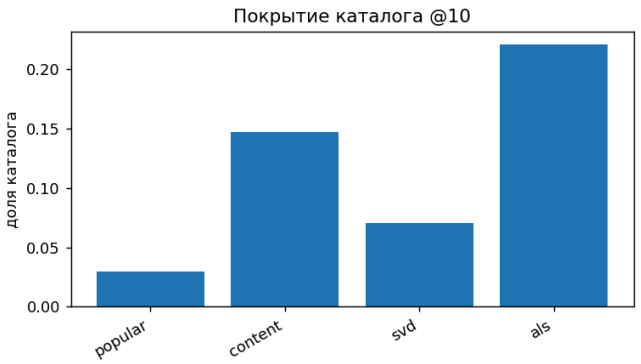


Рис. 2 - Покрытие каталога моделями на MovieLens (K = 10)

3. Методы и протокол оценки

Для корректного эксперимента реализован следующий протокол.

- **Сплит.** Поюзерный. MovieLens - хронологический (последние 5 взаимодействий пользователя в тест), так как есть временные метки. Last.fm - случайный leave-N-out (5 взаимодействий, seed = 42), так как времени прослушиваний в данных нет. Пользователи с историей менее 10 взаимодействий целиком остаются в train и в оценку не входят.
- **Бейзлайн.** Модель popular рекомендует каждому пользователю самые популярные из еще не виденных им объектов. Без нее оценка остальных моделей была бы невозможна.
- **Модели.** popular (бейзлайн); content (TF-IDF по жанрам, названиям и тегам, профиль пользователя - среднее векторов понравившегося, косинусное сходство); svd (матричное разложение на явных оценках, surprise); als (Alternating Least Squares на неявных данных, implicit). На MovieLens ALS обучался на бинаризованных данных: положительными считались оценки ≥ 4, поэтому он и SVD решают формально разные задачи.
- **Метрики.** Precision@K, Recall@K, MAP@K, NDCG@K (K = 10), а также покрытие каталога, разнообразие выдачи (intra-list diversity в пространстве TF-IDF), новизна и число жанров в списке. Ранжирование выполняется по всему каталогу за вычетом объектов из train.
- **Релевантность.** MovieLens: положительное взаимодействие - рейтинг ≥ 4. Last.fm: релевантно любое прослушивание.
- **Фильтрация.** Из обоих датасетов удалены пользователи и объекты с менее чем 5 взаимодействиями (k-core); дубликаты пар "пользователь–объект" схлопнуты.
- **Сегментация.** Метрики считались в целом и отдельно для "легких" (≤ 60 взаимодействий в train) и "тяжелых" (> 60) пользователей.
- **Значимость.** К метрикам приведены 95% доверительные интервалы по пользователям. Различие считается значимым, если интервалы не пересекаются (консервативный критерий).
- **Воспроизводимость.** Все запуски выполнены с seed = 42. Версии: scikit-surprise 1.1.5, implicit 0.7.3, numpy 2.2.6.
- **Лицензии.** MovieLens предоставлен GroupLens Research для некоммерческих исследований; Last.fm HetRec 2011 доступен для академических целей.

4. Результаты эксперимента

4.1. MovieLens (явные данные)

Модель	P@10	R@10	MAP@10 (± ci95)	NDCG@10 (± ci95)	Покры-тие	Разно-образие	Новизна	Жанров в списке
popular	0,0187	0,0531	0,0234 (± 0,0064)	0,0425 (± 0,0099)	2,9%	0,948	1,48	10,7
content	0,0020	0,0064	0,0015 (± 0,0011)	0,0038 (± 0,0023)	14,6%	0,288	5,45	6,85
svd	0,0084	0,0221	0,0080 (± 0,0033)	0,0170 (± 0,0056)	7,0%	0,966	3,25	11,0
als	0,0277	0,0868	0,0288 (± 0,0073)	0,0563 (± 0,0108)	22,0%	0,955	2,64	11,42

Таб. 1 - Результаты на MovieLens (K = 10, 95% доверительные интервалы)

1. SVD значимо хуже бейзлайна. MAP@10 у SVD 0,0080 ± 0,0033 против 0,0234 ± 0,0064 у popular; интервалы не пересекаются. SVD минимизирует RMSE, то есть ошибку предсказания самой оценки, и не оптимизирует ранжирование. Новизна SVD выше, чем у бейзлайна (3,25 против 1,48): он рекомендует более редкие фильмы. Это согласуется с предположением, что редким фильмам с малым числом высоких оценок он завышает предсказание, но напрямую это не проверялось - для проверки нужно сопоставить предсказанные и фактические оценки. Бейзлайн же рекомендует проверенные временем хиты.

2. ALS не отличим от бейзлайна. MAP@10 у ALS 0,0288 ± 0,0073, у popular 0,0234 ± 0,0064; интервалы пересекаются, на 610 пользователях нельзя утверждать, что ALS точнее. Зато покрытие каталога у ALS на порядок выше (22,0% против 2,9%). При этом ALS значимо лучше SVD (нижняя граница 0,0215 против верхней 0,0113), но это сравнение не вполне симметрично из-за разной постановки (бинаризованные данные у ALS).

3. Контентная модель значимо хуже бейзлайна (MAP@10 0,0015 ± 0,0011). Вероятная причина - слишком грубые признаки (жанры, названия, теги), по которым профиль пользователя плохо отличает фильмы; кроме того, модель не учитывает популярность. Выдача при этом самая однородная: разнообразие 0,288 и всего 6,85 жанра в списке против 11,42 у ALS.

Влияние объема истории. Преимущество ALS над бейзлайном сосредоточено среди легких пользователей и почти исчезает среди тяжелых (табл. 2).

Модель	MAP@10, легкие (≤ 60)	MAP@10, тяжелые (> 60)	Отношение легкие / тяжелые
popular	0,0270	0,0196	1,38
als	0,0366	0,0209	1,75
als / popular	1,36	1,07	-

Таб. 2 - MAP@10 по сегментам пользователей (MovieLens)

У обеих моделей метрика выше на легких пользователях, но ALS выигрывает у popular в 1,36 раза на легких и всего в 1,07 раза на тяжелых (NDCG@10 у ALS: 0,0703 и 0,0418). Возможное объяснение - у тяжелых пользователей более разнообразные вкусы, которые модель с фиксированными гиперпараметрами предсказывает хуже, - это гипотеза, не проверенная экспериментом. Доверительные интервалы для сегментов не приведены; в каждом сегменте около 300 пользователей, поэтому различия между сегментами следует считать ориентировочными.

4.2. Last.fm (неявные данные)

Модель	P@10	R@10	MAP@10 (± ci95)	NDCG@10 (± ci95)	Покрытие	Разнообразие	Новизна
popular	0,0428	0,0855	0,0390 (± 0,0040)	0,0772 (± 0,0065)	0,9%	0,684	2,29
content	0,0725	0,1450	0,0631 (± 0,0048)	0,1256 (± 0,0075)	52,4%	0,502	6,06
als	**0,0899**	**0,1797**	**0,0733 (± 0,0049)**	**0,1482 (± 0,0076)**	**54,2%**	**0,787**	**4,60**

Таб. 3 - Результаты на Last.fm (K = 10, 95% доверительные интервалы)

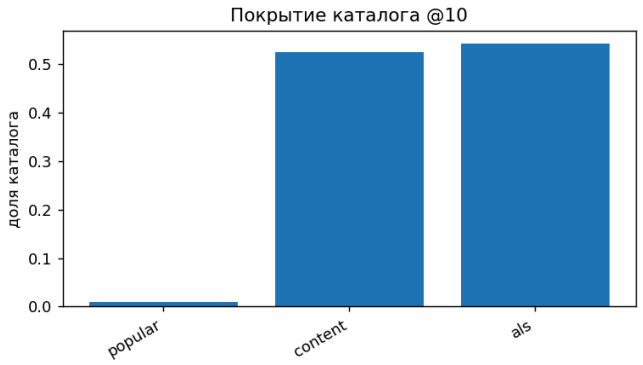


Рис. 3 - Покрытие каталога моделями на Last.fm (K = 10)

1. ALS лидирует. Его интервалы MAP@10 (0,0733 ± 0,0049) и у content (0,0631 ± 0,0048) не пересекаются, поэтому ALS значимо точнее контентной модели; обе модели значимо точнее бейзлайна (0,0390 ± 0,0040).

2. Бейзлайн дает очень низкое покрытие, но не нулевую точность. Покрытие popular - 0,9%: в выдачах всех пользователей вместе встречается около 28 разных исполнителей (0,99% от 2823), среди

них самые популярные (Lady Gaga, Britney Spears). По точности popular хуже ALS, но заметно лучше нуля (MAP@10 0,0390), то есть как бейзлайн он сильный. Для музыкального сервиса такая выдача была бы неприемлемо однообразной.

3. Контентная модель показала самую высокую новизну (6,06) и покрытие 52,4%, но точность ниже, чем у ALS. Возможная причина - шумность пользовательских тегов, на которых строятся признаки исполнителей.

4.3. Влияние MMR на разнообразие (MovieLens, контентная модель)

Для смягчения "пузыря фильтров" алгоритм MMR (Maximal Marginal Relevance) был применен к контентной модели, где проблема проявляется сильнее всего.

Модель	MAP@10	NDCG@10	Разнообразие (ILD)	Жанров в списке
Content (без MMR)	0,0015	0,0038	0,2880	6,85
Content + MMR (λ = 0,9)	0,0018	0,0041	0,2929	6,92
Content + MMR (λ = 0,7)	0,0019	0,0041	0,3203	7,27
Content + MMR (λ = 0,5)	0,0018	0,0045	0,3727	7,82

Таб. 4 - Влияние параметра λ в MMR (MovieLens, content, K = 10)

При λ = 0,5 разнообразие выдачи растет (ILD с 0,288 до 0,373, число жанров с 6,85 до 7,82). Рост ILD отчасти предсказуем: он измеряется в том же TF-IDF-пространстве, по которому MMR штрафует схожесть, поэтому надежнее ориентироваться на число жанров, где эффект скромнее (+14%). Точность практически не меняется: прирост MAP@10 с 0,0015 до 0,0018 лежит внутри интервала ± 0,0011 и не является значимым. Таким образом, на контентной модели MMR повышает разнообразие без видимой потери точности, но базовая точность этой модели настолько низка, что вывод о цене диверсификации сделать нельзя.

5. Ручной разбор рекомендаций

Для разбора выбраны по два пользователя на датасет (файлы cases.md). В скрытом тесте у каждого по пять релевантных объектов; сводка попаданий в top-10 приведена в таблице 5.

Пользователь (попаданий из 5)	popular	content	svd	als
MovieLens, № 53	0	0	0	0
MovieLens, № 55	0	0	0	1
Last.fm, № 168	0	0	-	0
Last.fm, № 174	0	2	-	0

Таб. 5 - Число попаданий в скрытый тест в top-10 (ручной разбор)

MovieLens, пользователь 53 (15 взаимодействий в train, все оценены на 5). История разнородна: комедии (Airheads, Return of the Pink Panther, Duck Soup), sci-fi и триллеры (The Arrival, Island of Dr. Moreau), романтика и драмы (Sunset Blvd., Days of Thunder, Benny & Joon), хоррор (Halloween). Скрытый тест - романтика, драма, триллер (Roman Holiday, Immortal Beloved, When a Man Loves a Woman, Kalifornia, The Ghost and the Darkness). Ни одна модель не попала ни в один из пяти фильмов.

- **ALS:** "Kingpin" и "Clerks" продолжают комедийную линию истории - согласна. Но остальная выдача (Citizen Kane, The Sting, The Thin Red Line, American History X) - признанная классика без явной связи с историей пользователя; ближе всего к тесту "Jerry Maguire" (романтика).
- **Content:** первые шесть рекомендаций - драмы и романтические драмы ("The Descendants", "The Cooler", "The Artist", "The Majestic"), затем четыре комедии. По жанровым меткам это ближе всего к скрытому тесту (Roman Holiday - Drama и Romance), хотя попаданий нет. Выдача однородна: современные комедийные и романтические драмы.

- **SVD:** "Godfather", "Shawshank Redemption", "Fight Club", "Pulp Fiction" - три из десяти рекомендаций совпадают с бейзлайном popular. Это согласуется с метриками: SVD рекомендует признанные хиты и слабо персонализирован. "Dr. Strangelove" в MovieLens помечен жанром War.
- **Popular:** список один и тот же для всех пользователей (у пользователя 55 он идентичен): "Shawshank Redemption", "Forrest Gump", "Pulp Fiction"… Не согласна как с персональной рекомендацией.

MovieLens, пользователь 55 (20 взаимодействий, оценки от 0,5 до 4,5). В истории преобладают криминальные триллеры и драмы (Lucky Number Slevin, Crash, Bourne Ultimatum, Ronin, Payback); скрытый тест - криминальные триллеры (Lock, Stock and Two Smoking Barrels, Snatch, Layer Cake, The Departed, The Boondock Saints).

- **ALS:** единственная модель с попаданием - "The Departed" (6-е место). Рядом "Bourne Supremacy", "Italian Job", "Enemy of the State", "Batman Begins" - тот же криминально-триллерный кластер; согласна с выдачей.
- **Content:** жанр угадан (Crime/Thriller: "Fracture", "Swordfish", "Smokin' Aces"), но попаданий нет: по жанровым меткам нельзя отличить нужные фильмы от десятков других криминальных. Часть выдачи ("Elektra", "Spectre", "Highlander: Endgame") - боевики, а не детективные триллеры.
- **SVD:** общие хиты ("American History X", "Shawshank", "Forrest Gump"), без попаданий; "Trainspotting" (Crime и Drama) ближе к вкусу пользователя.

Last.fm, пользователь 168 (33 взаимодействия). История - инди и электроника (Animal Collective, Why?, Flying Lotus, of Montreal, Deerhunter, Boards of Canada, Burial). Скрытый тест: Gorillaz, Los Campesinos!, Daedelus, Fever Ray, Foals.

- **ALS:** инди-часть профиля отражена хорошо (Beirut, Neutral Milk Hotel, Yeasayer, Bon Iver, Sigur Rós, The Flaming Lips) - согласна, исполнители близки по духу. Однако попаданий нет, и почти не отражена электронная ветвь истории (Flying Lotus, Burial, Boards of Canada, Bonobo), к которой относятся Daedelus и Fever Ray из теста.
- **Content:** смешанная выдача (Thom Yorke, M83, Beach House, The Postal Service, Moby), включает и электронику, но тоже без попаданий.
- **Popular:** Lady Gaga, Britney Spears, Rihanna - не согласна, это не связано с нишевыми вкусами пользователя.

Last.fm, пользователь 174 (40 взаимодействий). В истории поп-рок и singer-songwriter 1990–2000-х (John Mayer, Hanson, Coldplay, Death Cab for Cutie, Dave Matthews Band, Snow Patrol). Скрытый тест: James Blunt, The Doors, Foo Fighters, Goo Goo Dolls, Third Eye Blind.

- **Content:** два попадания из пяти ("Goo Goo Dolls" на первом месте, "James Blunt" на шестом); выдача (Jason Mraz, Jack Johnson, Jeff Buckley, Alanis Morissette) точно отражает вкус - согласна.
- **ALS:** ноль попаданий. Выдача (Maroon 5, Weezer, Led Zeppelin, Oasis, Pearl Jam, The Beatles, Elvis Presley) в целом подходит под "рок", но тяготеет к самым известным исполнителям и менее специфична, чем у контентной модели.

Выводы разбора. (1) Попаданий в тест мало: во всех 14 парах "модель - пользователь" вместе набралось только 3 попадания (при 5 скрытых объектах на пользователя), поэтому отсутствие попадания нельзя считать ошибкой модели - выдача может быть разумной, а тест слишком мал. (2) Рейтинг моделей зависит от пользователя: на агрегированных метриках ALS лидирует на Last.fm, а у пользователя 174 контентная модель попала дважды, а ALS - ни разу. (3) Контентная модель на Last.fm по метрикам намного сильнее, чем на MovieLens; вероятная причина - более информативные теги исполнителей по сравнению с жанрами фильмов (гипотеза). Разбор основан на четырех пользователях и носит иллюстративный характер.

6. Обсуждение: проблема "пузыря фильтров"

Бейзлайн popular создает "глобальный пузырь": всем показывают почти одно и то же (покрытие 0,9% на Last.fm и 2,9% на MovieLens). Контентная модель создает "персональный пузырь": на MovieLens ее выдача самая однородная (разнообразие 0,288, 6,85 жанра в списке против 11,42 у ALS), то есть пользователя замыкает в узком круге жанров. ALS дает наибольшее покрытие (22,0% на MovieLens, 54,2% на Last.fm) и разнообразие на уровне бейзлайна, однако на MovieLens по точности значимо не превосходит popular, поэтому говорить о "лучшем балансе" можно только на Last.fm, где ALS значимо точнее и бейзлайна, и контентной модели.

MMR на контентной модели повышает разнообразие (число жанров с 6,85 до 7,82) при неизменной в пределах погрешности точности. Это относительно дешевый прием, не требующий переобучения, но его эффект на метриках ILD частично объясняется самим способом измерения. Выбор λ - компромисс, зависящий от продукта, универсального значения нет.

7. Ограничения

3. Гиперпараметры (50 факторов, число итераций) взяты из стартовых рекомендаций лекции; подбор на валидационной выборке не проводился.
4. Last.fm: временных меток нет, использован случайный leave-N-out. Это может завышать метрики, так как модель видит прослушивания, которые по времени могли быть после тестовых.
5. Холодный старт не тестировался: в датасетах после k-core фильтра нет новых пользователей и объектов, а в MovieLens (ml-latest-small) его почти нет и по природе данных. Результаты SVD и ALS могут быть оптимистичнее, чем в реальной среде.
6. Пользователи с историей менее 10 взаимодействий в оценку не вошли, как и пользователи без релевантных объектов в тесте.
7. Значимость проверялась по пересечению доверительных интервалов (консервативно), без парного теста или bootstrap. Для сегментов интервалы не рассчитывались.
8. Разнообразие считается в том же TF-IDF-пространстве, в котором работают контентная модель и MMR, поэтому оно смещено в их пользу.
9. ALS на MovieLens обучался на бинаризованных оценках, SVD - на исходных, поэтому их сравнение не полностью симметрично.
10. Ручной разбор выполнен для четырех пользователей (по два на датасет) и не репрезентативен.

Заключение

Обучены и сравнены четыре модели на двух датасетах. На явных данных (MovieLens) SVD значимо уступил бейзлайну, а контентная модель - тем более; ALS по точности не отличим от бейзлайна, но дает на порядок большее покрытие и значимо лучше SVD. Преимущество ALS сосредоточено у пользователей с короткой историей. На неявных данных (Last.fm) ALS значимо точнее и контентной модели, и бейзлайна, и обеспечивает покрытие 54,2% против 0,9%. Простейший бейзлайн оказался сильным соперником, что подтверждает необходимость сравнения с ним. MMR повышает разнообразие контентной выдачи без значимой потери точности. Пайплайн воспроизводим (CLI, seed = 42). Основные ограничения: не проведен подбор гиперпараметров, не тестировался холодный старт, значимость оценена консервативным методом.